自然语言处理大作业

QQ群号：1125830641



1.机器翻译

1.了解Word Embedding的相关知识
2.了解Transformer
3.了解机器翻译的过程
4.了解机器翻译的评价标准

Word Embedding

- 什么是Word Embedding?

现有的机器学习方法往往无法直接处理文本数据，因此需要找到合适的方法，将文本数据转换为数值型数据，由此引出了Word Embedding的概念。如果将word看作文本的最小单元，可以将Word Embedding理解为一种映射，其过程是：将文本空间中的某个word，通过一定的方法，映射或者说嵌入（embedding）到另一个数值向量空间。

Word Embedding

- One-hot编码

One-hot编码是词汇表征的一种简单形式。每个单词都被映射到一个与词汇表大小相同的向量中。在这个向量中，表示该单词的位置为1，其余位置为0。例如，如果词汇表包含五个单词["cat", "dog", "fish", "bird", "horse"]，单词"cat"的one-hot编码可能是[1, 0, 0, 0, 0]。

- One-hot编码的缺点

维度高：如果词汇表很大，每个单词的向量也会非常大。

稀疏性：除了一个位置为1之外，向量的其余部分都是0。

缺乏语义信息：One-hot编码不包含任何单词之间的语义信息。"cat"和"dog"可能在语义上很接近，但它们的one-hot向量却是正交的。

Word Embedding

- Word Embedding

Word Embedding是一种更为高级和密集的词汇表示方法。每个单词被映射到一个更小的、连续的、密集的向量空间中。这些向量由模型在训练过程中学习，以便能够捕捉和表示词汇之间的语义和句法关系。

- Word Embedding编码的优点

低维度：相比于one-hot编码， Word Embedding的维度通常较低。

密集表示： Word Embedding的每个维度都包含某种信息，没有零值浪费。

语义信息： Word Embedding捕获了单词的语义信息，意味着在向量空间中相互接近的单词在语义上也更为接近。

RNN

- 什么是RNN?

循环神经网络（Recurrent Neural Network，RNN）是一种专门用来处理序列数据的神经网络。与传统的前馈神经网络不同，RNN能够处理序列中的时间动态信息，因此非常适合语言模型等需要考虑时间顺序的任务。

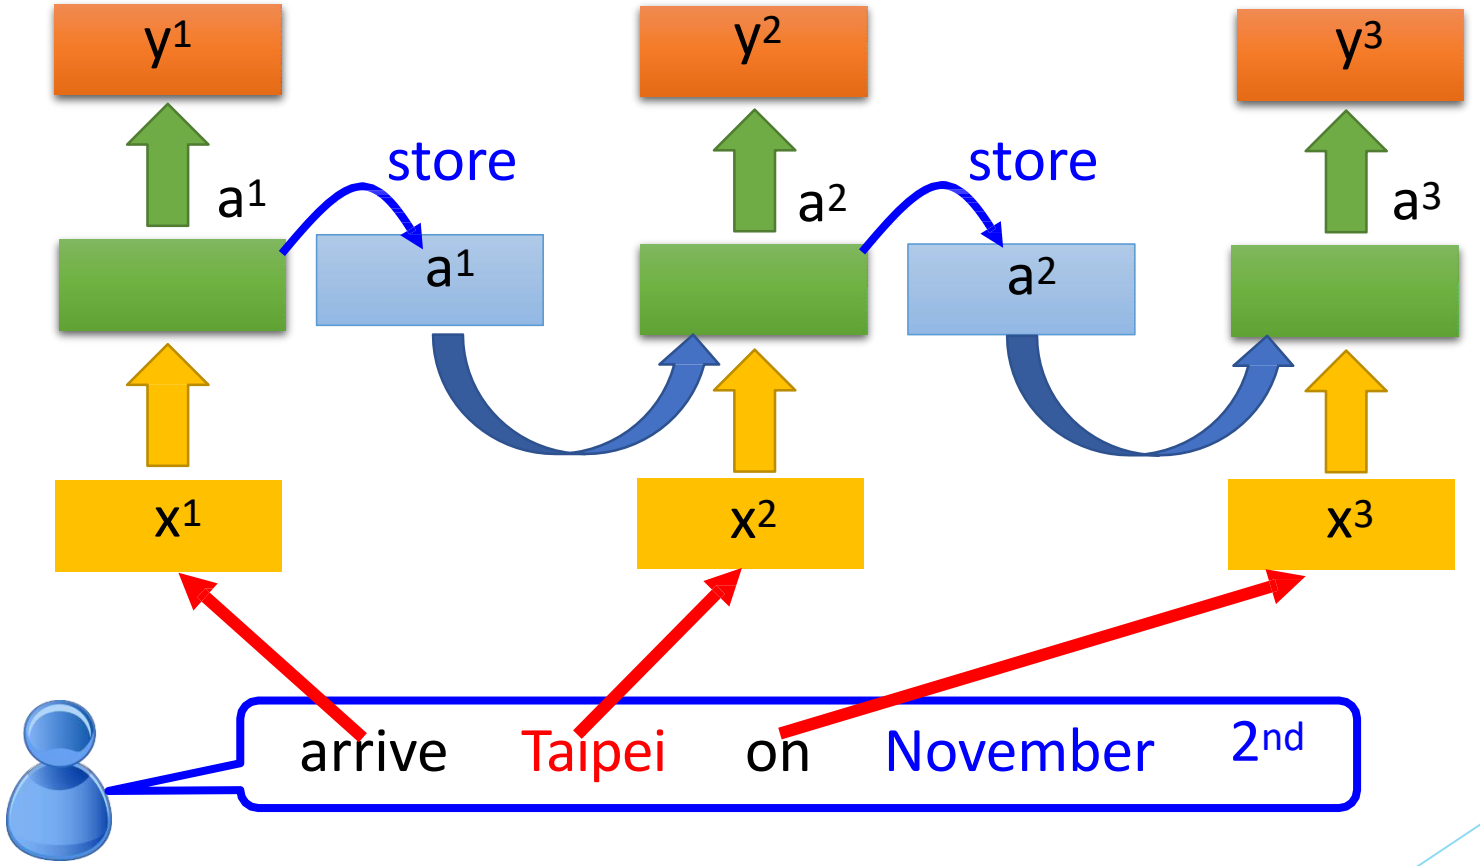
RNN的核心思想是使用循环的连接来保持一个内部状态，该状态能够捕获到目前为止的序列信息。在每个时间步骤，RNN都会接收两个输入：一个是当前时间步骤的外部输入，另一个是上一个时间步骤的内部状态。这样，网络就能够在处理每个新输入时，同时考虑之前接收过的所有输入。

RNN

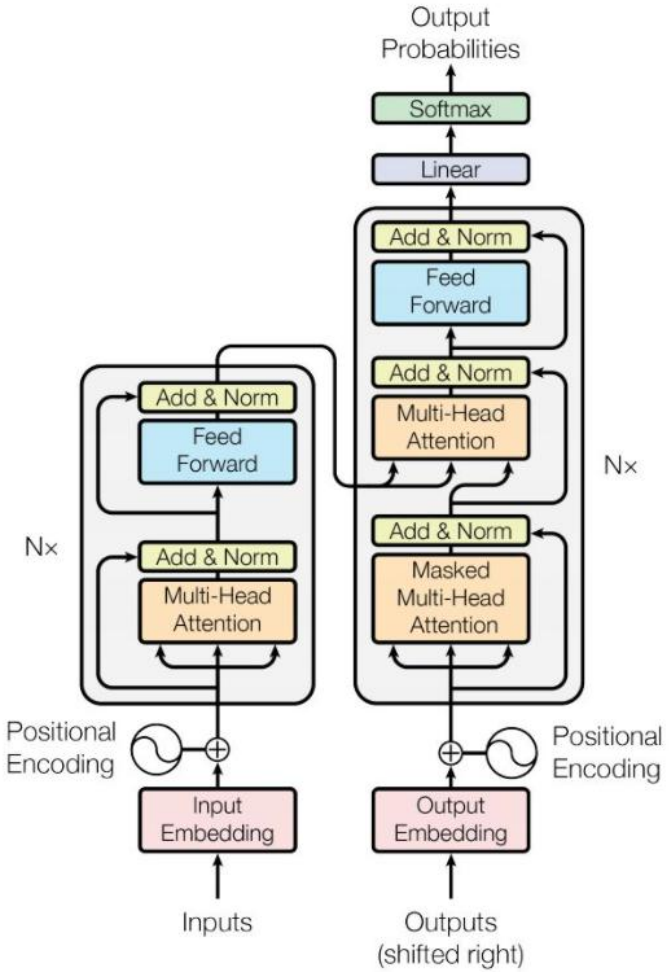
Probability of "Taipei" in each slot

Probability of "on" in each slot

Probability of "November" in each slot



Transformer



- 什么是Transformer?

Transformer改进了RNN最被人诟病的训练慢的缺点，利用Self-Attention机制实现快速并行。并且Transformer可以增加到非常深的深度，充分发掘DNN模型的特性，提升模型准确率。Transformer的结构是由Encoder和Decoder组成。

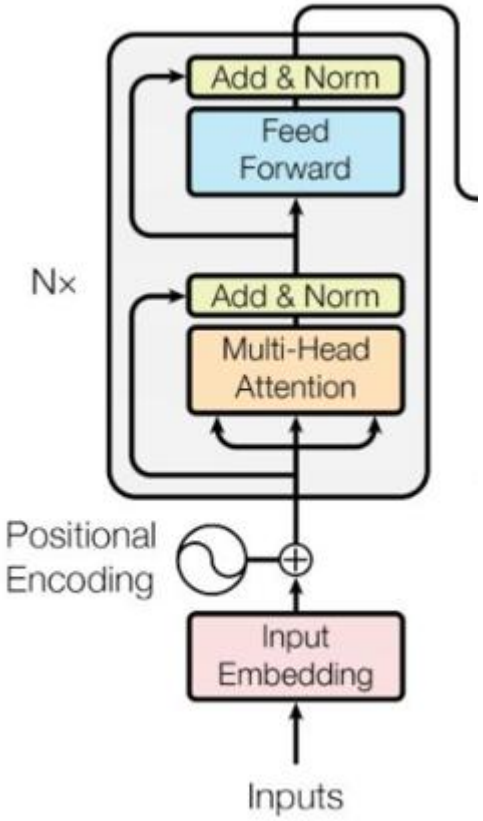
Transformer

- Encoder

Encoder由N=6个相同的layer组成，layer指的就是右侧的单元。每个Layer由两个sub-layer组成，分别是Multi-head Self-attention Mechanism和Fully Fonnected Feed-Forward Network。其中为了更好地优化网络，每个sub-layer都加了Residual Connection和Layer Normalization，因此可以将sub-layer的输出表示为：

$$sub_layer_output = LayerNorm(x + (SubLayer(x)))$$

思考：FFN的结构是什么？



Transformer

- Multi-head Self-attention

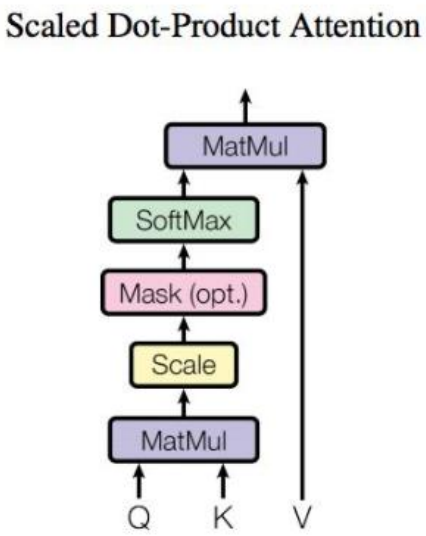
自注意力机制可以看做是将查询向量Query、被查询向量 Key 和真实向量 Value 映射到一个输出的过程。首先将输入的文本分别映射为矩阵Q 、K 和V（如右图），自注意力机制计算如下：

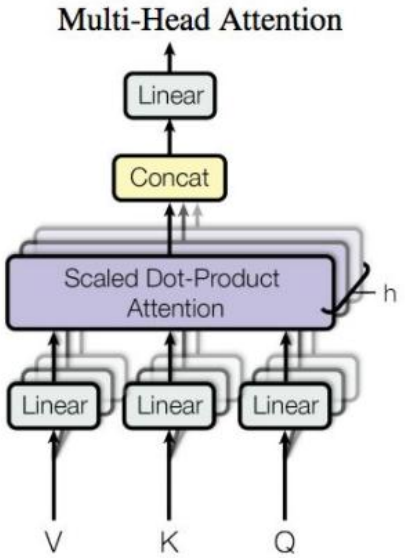
$$Attention(Q,K,V) = softmax(\frac{QK^T}{\sqrt{d_k}})V$$

Multi-head Attention则是通过h个不同的线性变换对Q，K，V进行投影，最后将不同的Attention结果拼接起来：

$$MultiHead(Q,K,V) = Concat(head_1,\dots,head_h)W^O$$

$$head_i = Attention(QW_i^Q, KW_i^K, VW_i^V)$$





Transformer

- Decoder

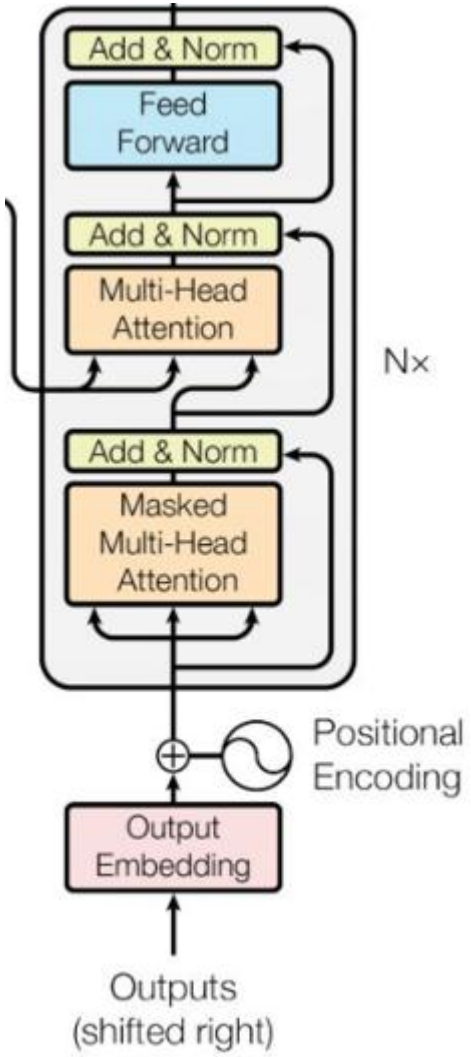
Decoder和Encoder的结构类似，区别是多了一个attention的sub-layer。

Decoder的输入输出和解码过程：

输出：对应i位置的输出词的概率分布

输入：Encoder的输出 & 对应i-1位置Decoder的输出。

所以中间的Attention不是self-attention，它的K，V来自Encoder，Q来自上一位置Decoder的输出。



Transformer

- Positional Encoding

位置编码是Transformer框架中特有的组成部分，补充了Attention机制本身不能捕捉位置信息的缺陷。

$$PE_{(pos,2i)} = sin(pos/10000^{2i/d_{model}})$$

$$PE_{(pos,2i+1)} = cos(pos/10000^{2i/d_{model}})$$

如pos=3,d(model)=128,那么3对应的位置向量如

$[sin(3/10000^{0/128}), cos(3/10000^{1/128}), sin(3/10000^{2/128}), cos(3/10000^{3/128}), \ldots]$

机器翻译

- 背景

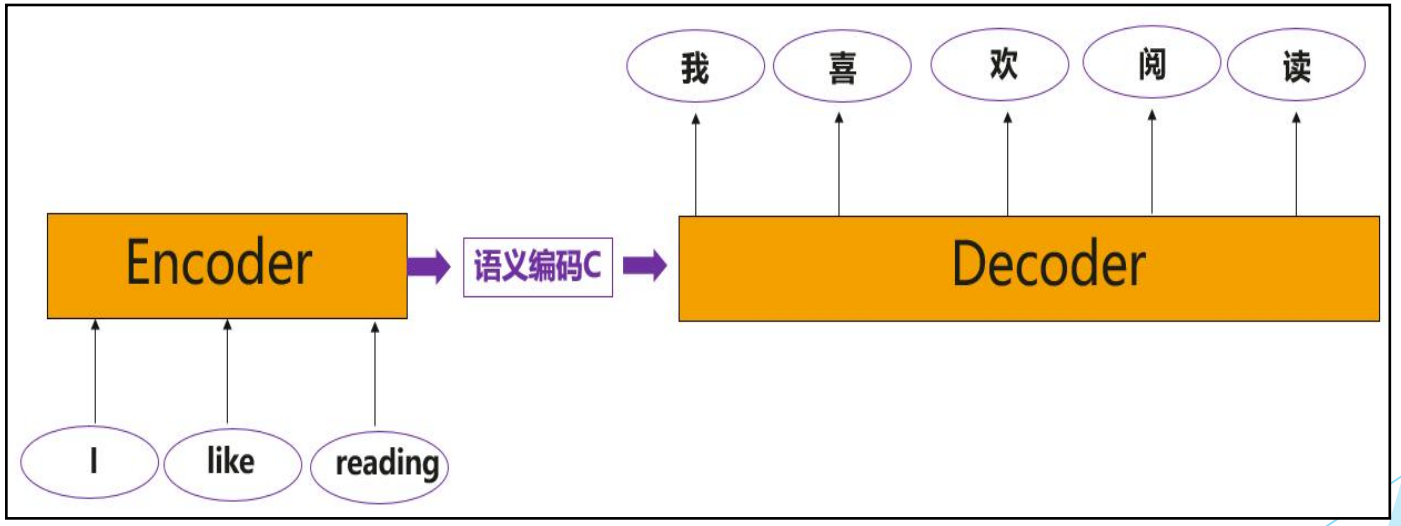
在实际生活中，机器翻译是人工智能技术比较广泛的一个应用，在之前的深度学习过程中，我们知道，循环神经网络能将输入序列映射成等长的输出序列，但在机器翻译应用中，输入序列与输出序列的长度通常不一样。序列到序列（Sequence to Sequence, Seq2Seq）的映射框架，就是用来解决这一问题，它能将一个可变长序列映射到另一个可变长序列。

机器翻译

- 实验内容

用Transformer实现机器翻译。

Hi.	嗨。
Hi.	你好。
Run.	你用跑的。
Wait!	等等！
Hello!	你好。
I try.	让我来。
I won!	我赢了。
Oh no!	不会吧。
Cheers!	干杯！
He ran.	他跑了。



机器翻译评价指标

- BLEU

BLEU（Bilingual Evaluation Understudy）是一种评估机器翻译质量的方法，通过测量机器译文与一个或多个参考译文间的重叠度来进行评分。BLEU计分主要考虑了准确率（precision）的不同n-gram长度，以及为了避免过短译文带来的不当优势而引入的句子长度惩罚因子（brevity penalty, BP）。

BLEU分数的计算公式如下：

$$\mathrm{BLEU} = \mathrm{BP} \cdot \exp\left(\sum_{n=1}^{N} w_n \log p_n\right)$$

$$\mathrm{BP} = \begin{cases} 1 & \text{if } c > r \\ e^{(1-r/c)} & \text{if } c \leq r \end{cases}$$

2.命名实体识别

1.了解命名实体识别的相关知识
2.了解Bert的相关知识
3.了解本实验的过程及其评价标准

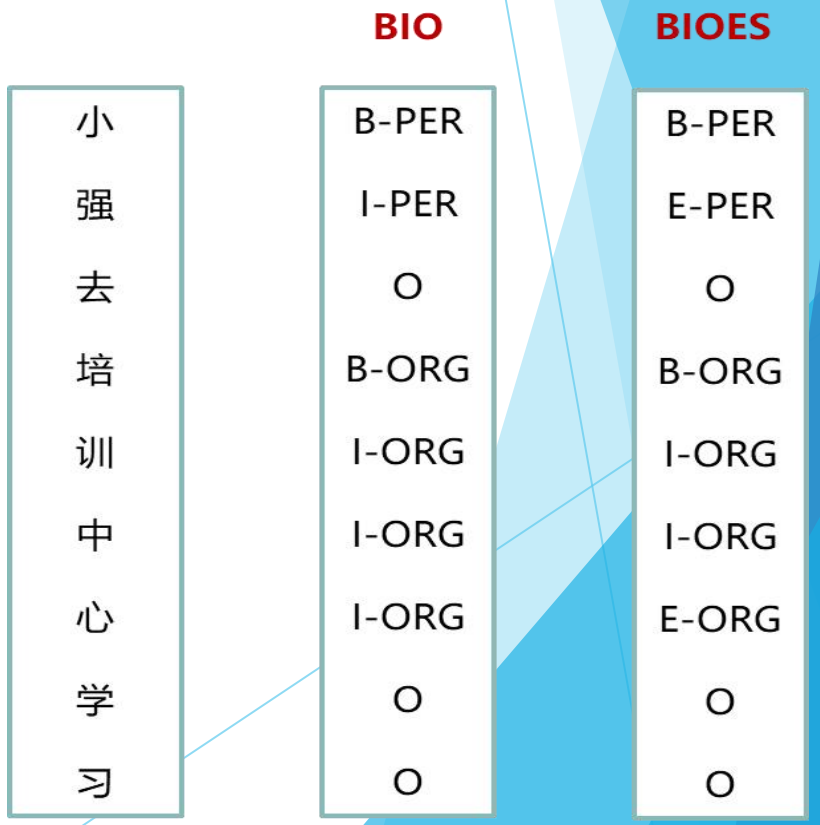
命名实体识别

- 背景

命名实体识别（Named Entity Recognition, NER) 是NLP领域最经典的任务之一，实体识别提取一些专有的实体，如人名，地名，机构名，公司名，药品名等，实体识别广泛应用于搜索，对话，问答，知识库构建等场景中。

- BIO和BIOES标注

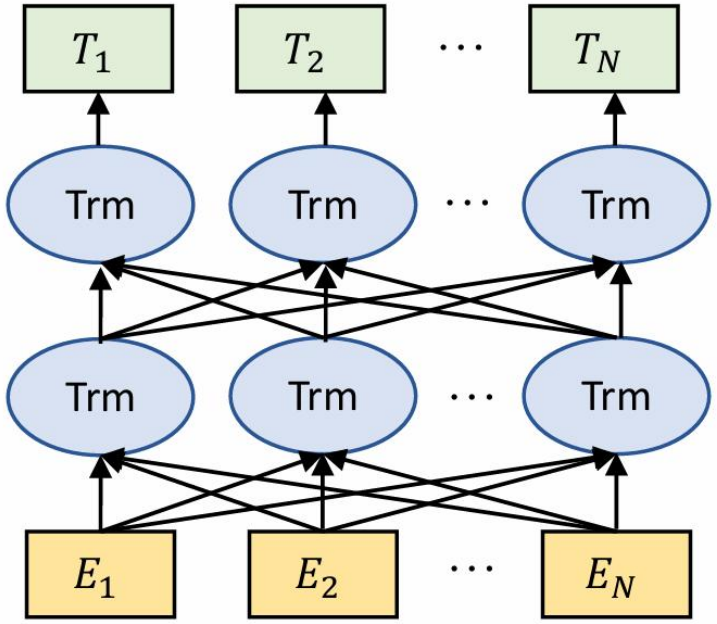
B代表begin, I代表inner, O代表other, E代表end, S代表single(表示这个实体只有一个词)，PER或ORG代表实体的类别，PER代表Person (人名)，ORG代表Organization （机构名）。

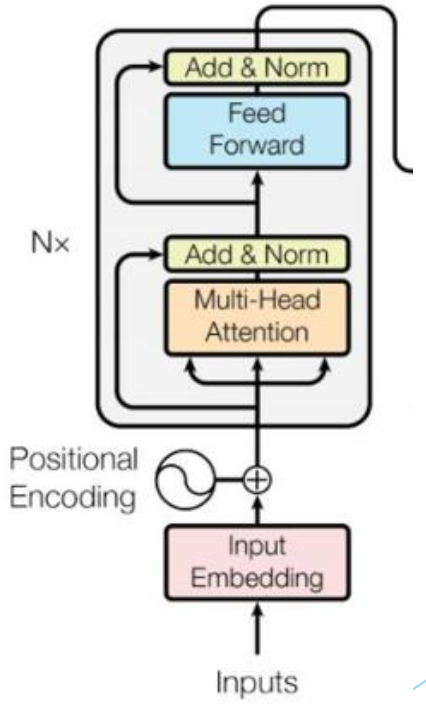


BERT

- 什么是BERT?

BERT（Bidirectional Encoder Representations from Transformers）是一种预训练语言表示模型。BERT 选用双向的Transformer Encoder作为特征抽取结构，这也意味着 BERT 无法适用于自回归语言模型的预训练方式，因此，BERT提出了两种预训练任务来对其模型进行预训练。





BERT

- 预训练任务

Task 1: MLM（Masked Language Model ）

随机从输入预料上 mask 掉一些单词，然后通过上下文预测该单词，类似于一个完形填空任务。在预训练任务中，15%的 Word Piece 会被mask，这15%的 Word Piece 中，80%的时候会直接替换为 [Mask]，10%的时候将其替换为其它任意单词，10%的时候会保留原始Token。例如：

- 80%: `my dog is hairy -> my dog is [mask]`
- 10%: `my dog is hairy -> my dog is apple`
- 10%: `my dog is hairy -> my dog is hairy`

Task 2: NSP（Next Sequence Prediction）

具体任务即为一个句子关系判断任务，即判断句子B是否是句子A的下文。



BERT

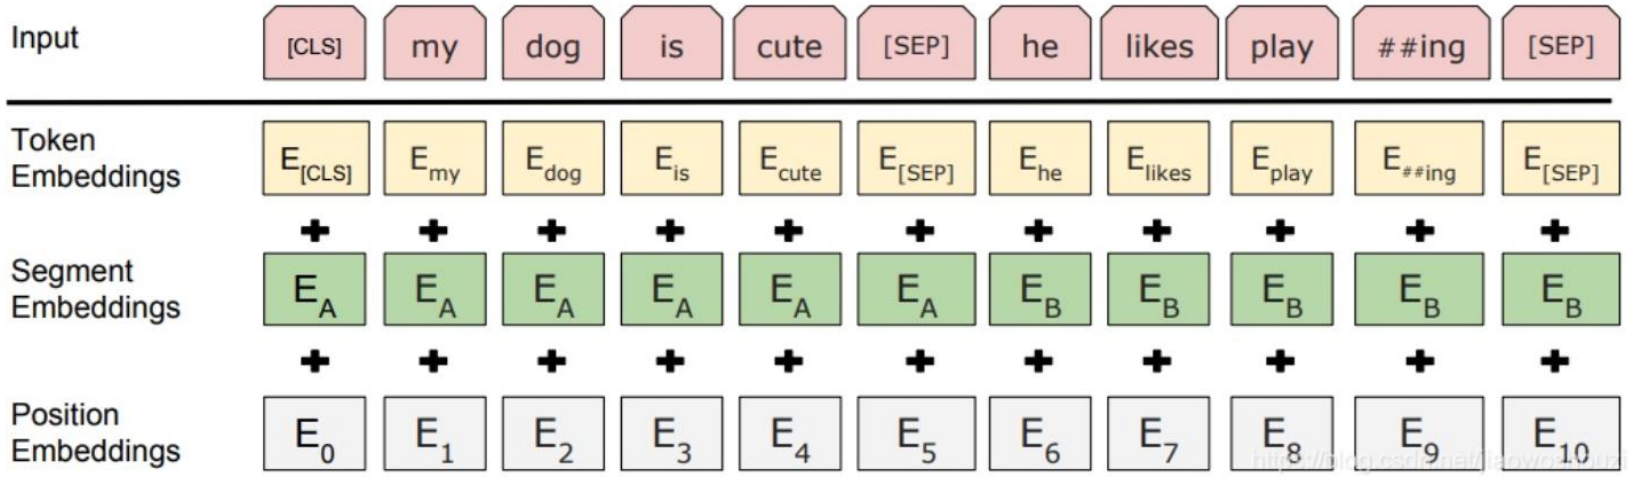
- 输入表征

BERT的输入表征由三种Embedding求和而成：

Token Embeddings：即传统的词向量层，每个输入样本的首字符需要设置为[CLS]，可以用于之后的分类任务。

Segment Embeddings：为[0,1]序列，用来在NSP任务中区别两个句子。

Position Embeddings：与Transformer中的位置向量不同，BERT中的位置向量是直接训练出来的。



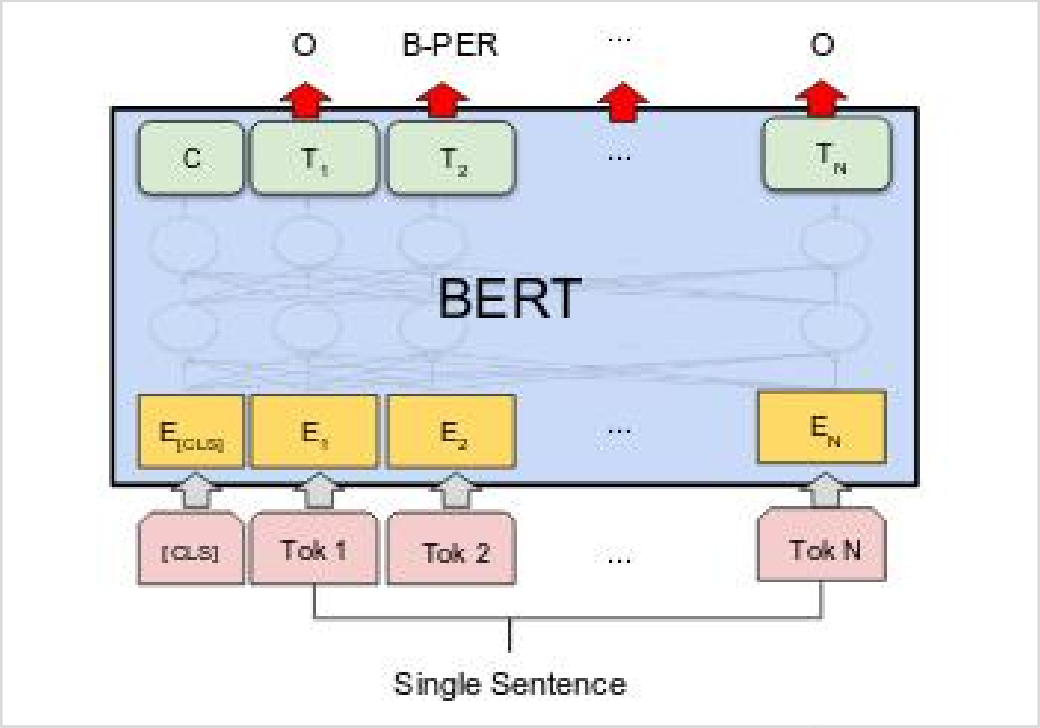
基于BERT的命名实体识别

- 基本原理

在每一个输入对应的位置上输出，做一个多分类，得到对应的标签。

- 模型微调

将预训练模型应用于下游任务时，不需要设计特定的神经网络结构，只需要“微调”预训练模型，即使用具体任 务的标注数据在预训练语言模型上进行监督训练，就可以取得显著的性能提升。



基于BERT的命名实体识别

- 评价指标

准确率（Precision）

准确率是指模型预测为正类的样本中，实际上为正类的比例。准确率的计算公式为：

$$\text{Precision} = \frac{TP}{TP + FP}$$

召回率（Recall）

召回率是实际为正类的样本中，模型正确预测为正类的比例。召回率的计算公式为：

$$\text{Recall} = \frac{TP}{TP + FN}$$

F1 Score

F1分数是准确率和召回率的调和平均数，试图在两者之间提供一个平衡。F1分数的计算公式为：

$$\text{F1 Score} = 2 \cdot \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

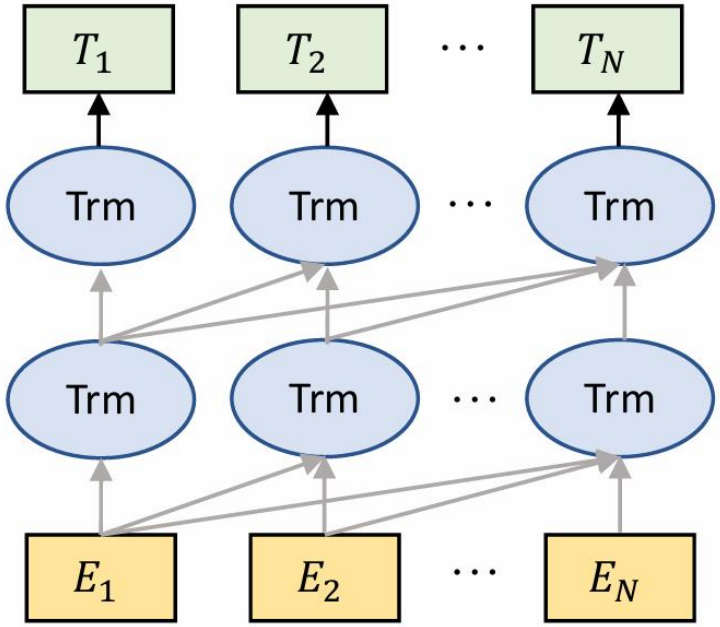
3. 大模型参数高效微调

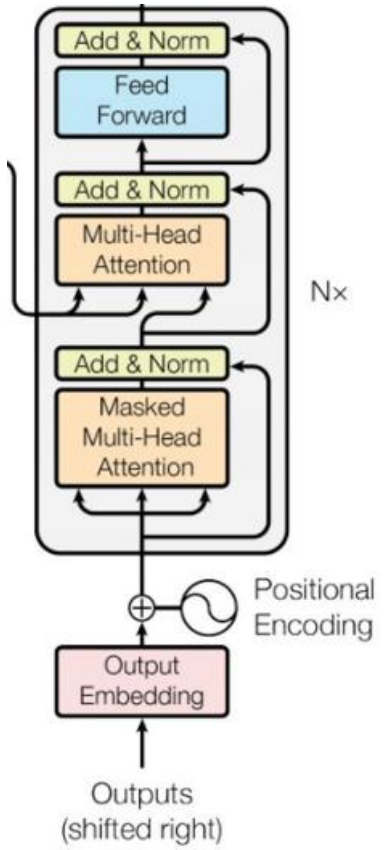
1.了解大模型的相关知识
2.了解Lora的相关知识
3.了解本实验的过程

生成式预训练模型

- 什么是GPT?

OpenAI 公司在2018年提出的生成式预训练模型（GenerativePre-Training，GPT） 是典型的生成式预训练语言模型之一。GPT模型结构如图所示，由多层Transformer组成的单向语言模型，主要分为输入层，编码层和输出层三部分。



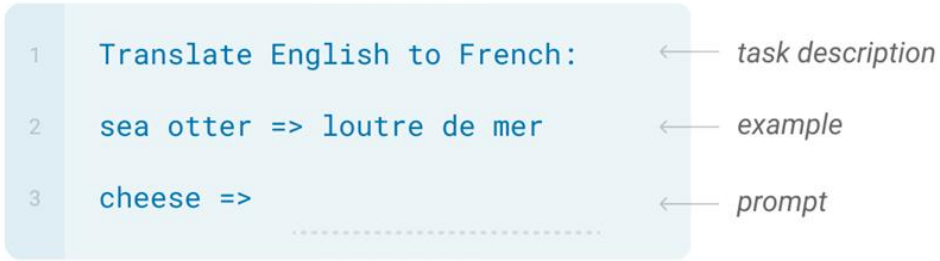


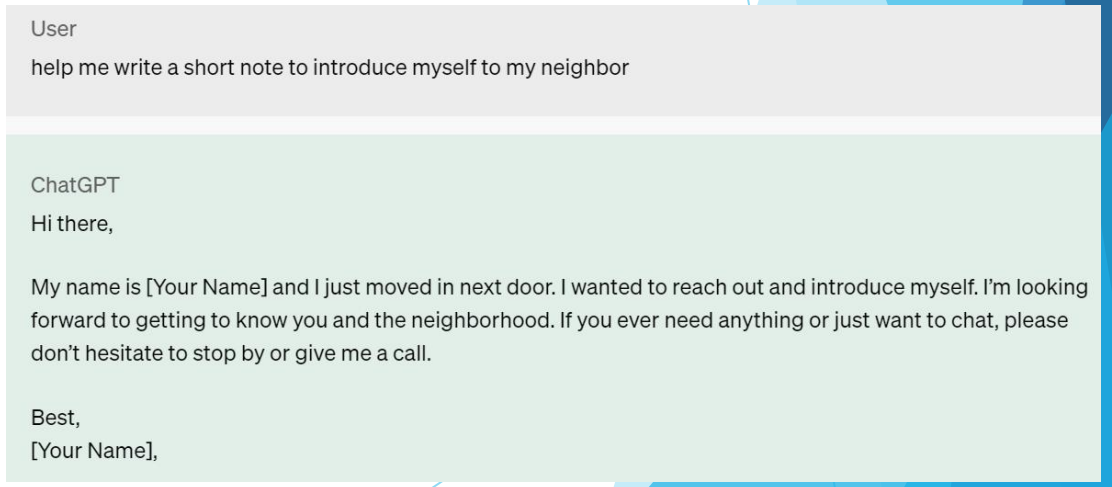
生成式预训练模型

- InstructGPT

以 GPT-3 为代表的语言模型在面对各式各样的下游任务，可以在不训练任何参数的情况下，仅仅借助其强大的 In-Context Learning 的能力完成下游任务，但它们不擅长遵循用户的意图，生成的文本是不受控的。

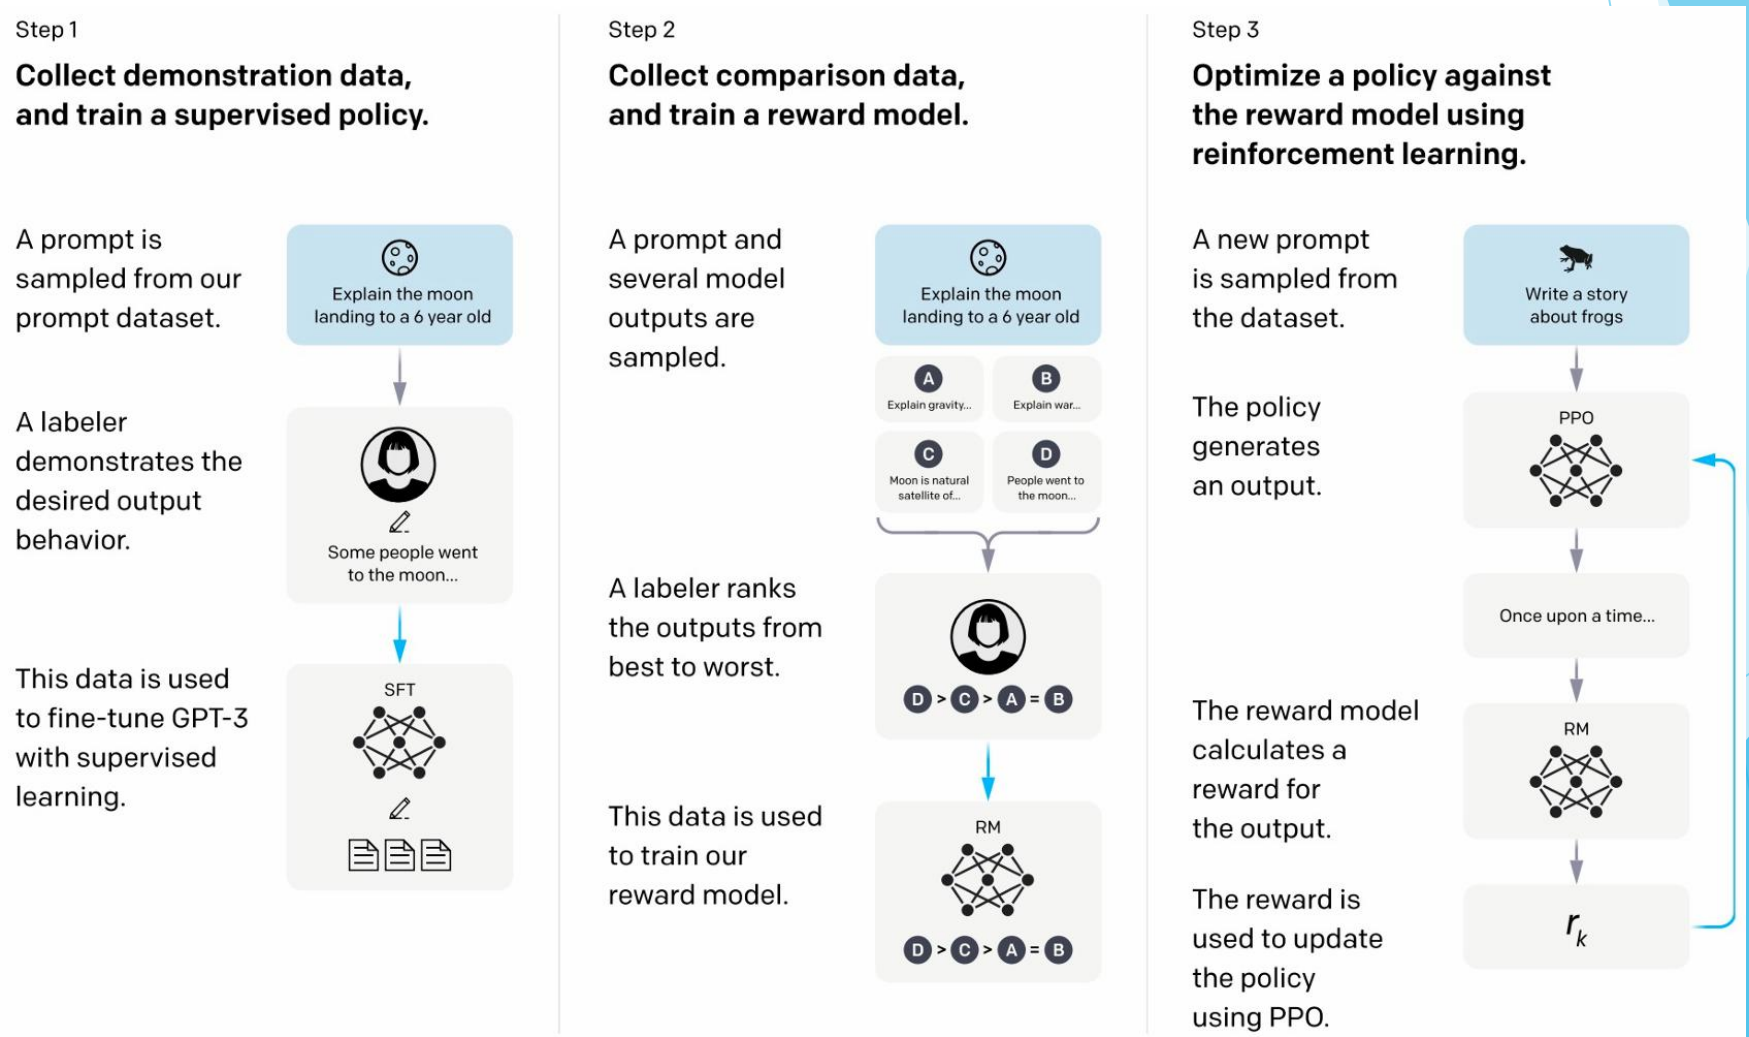
InstructGPT 的作者团队构造了一个带有人类指令的数据集，并使用这个标注的数据微调 GPT-3。





生成式预训练模型

- InstructGPT



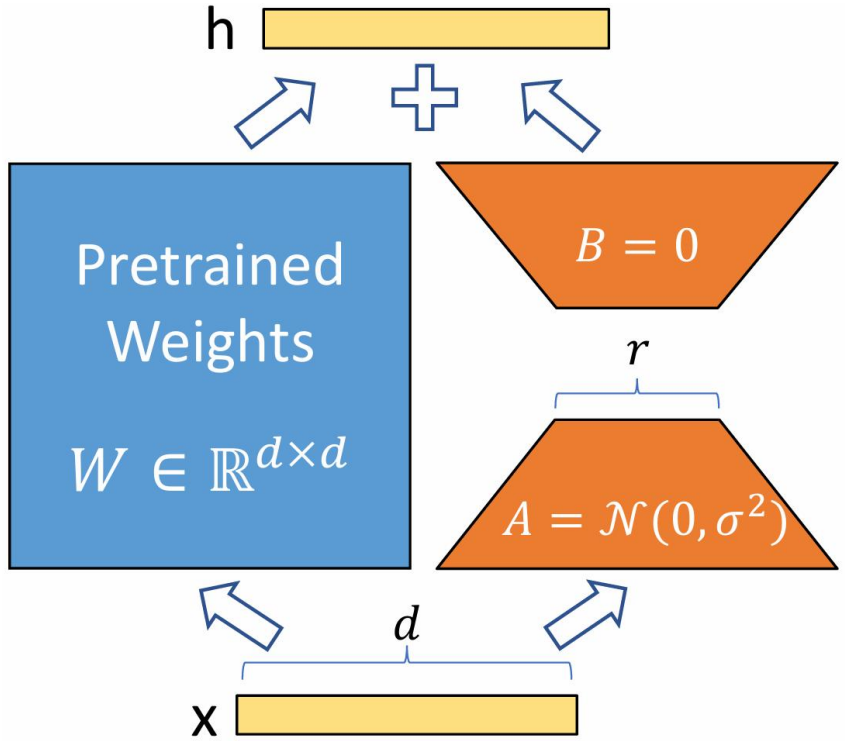
Lora

- Low-Rank Adaptation

LoRA是一种高效的大语言模型微调技术，它通过在预训练模型的基础上添加少量可训练参数来实现模型适应特定任务，而无需修改原始模型的权重。

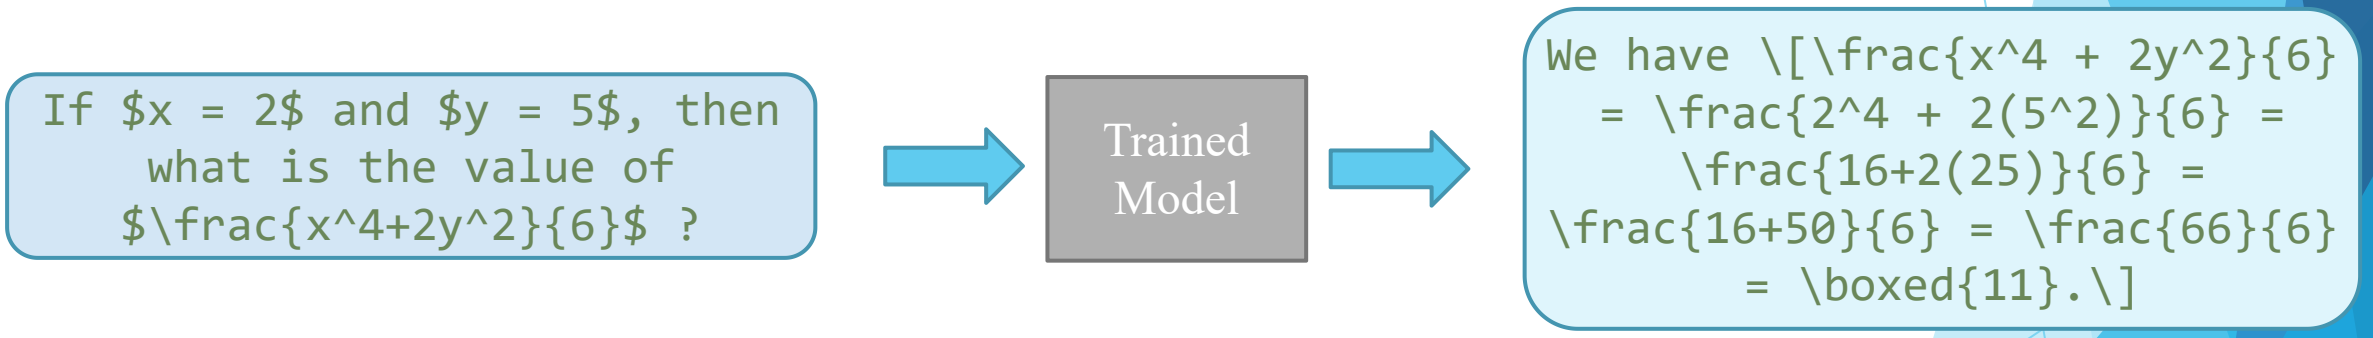
LoRA基于一个重要假设：模型适应过程中的权重变化具有低秩特性。

$$h = W_0 x + \Delta W x = W_0 x + BAx$$



实验内容

- 在数学数据集上利用Lora进行模型微调
- 在测试集上统计准确率



3.作业要求

1.实验组队人数

3人

2.实验报告

1）机器翻译

2）命名实体识别

3）大模型参数高效微调

3.报告的提纲

1）背景和问题介绍

2）目前的研究现状

3）模型与算法设计

4）实验结果与分析

5）总结

4.需要介绍组员的工作

提交邮箱：

nlp_course_ustc@163.com

命名格式：26年秋实验报告_第x组_组长姓名_组长学号